

Valutazione del consumo energetico di Large Language Model in dispositivi dell'Internet delle Cose

Tesi di Laurea in
Ingegneria Informatica

Candidato
Dario Guidi

Relatore
Prof. Alessio Vecchio



UNIVERSITÀ DI PISA

Introduzione e Problema

- I Large Language Model si stanno diffondendo rapidamente, ma comportano consumi energetici elevati. Eseguirli localmente su dispositivi edge/IoT, grazie alla quantizzazione, è una via verso un'IA più sostenibile (Green Edge AI).
- Problema
 - Un dispositivo a risorse limitate come il Raspberry Pi 5 può eseguire LLM quantizzati in modo efficiente? E con quale compromesso tra consumo energetico, qualità delle risposte e latenza?

- 6 modelli quantizzati
 - qwen 1.5B, gemma 2B, Llama 3B — a 4 e 8 bit — eseguiti con llama.cpp
- Consumo misurato dal PMIC
 - potenza letta dai 12 rami interni del Raspberry Pi 5, senza strumenti esterni
- 5 benchmark
 - CommonsenseQA, BIG-Bench Hard, TruthfulQA, GSM8K, HumanEval: energia, qualità e latenza
- Due campagne di misura
 - A: confronto tra i modelli (2 thread); B: effetto del parallelismo (1, 2, 4 thread)

- Sintesi dei risultati
 - Miglior configurazione
 - ⇒ qwen2.5-1.5B a 4 bit, 2 thread: miglior compromesso energia–qualità–latenza
 - Quantizzazione a 4 bit conveniente
 - ⇒ qualità equivalente agli 8 bit, ma circa il 18% di energia in meno e minore latenza
 - Parallelismo: 2 thread ottimali
 - ⇒ oltre i 2 thread non si guadagna (collo di bottiglia: la banda di memoria)
 - Raspberry Pi 5 adeguato (8 GB di RAM)
 - ⇒ esegue LLM fino a ~3 miliardi di parametri quantizzati
 - ⇒ senza incorrere in throttling termico